



SEGMENTASI PELANGGAN

MENGGUNAKAN ALGORITMA
K-MEANS CLUSTERING

BERDASARKAN KARAKTERISTIK & PERILAKU BELANJA

KITA DI CARRY AZIZ RKA NRP 002

AZIZ RAHMAD ARIFIN RKA 002

ISHAM HAWALI ARIJUDDIN IF 079

SULAIMAN FAIZ TSAQIB RKA 048

COKORDA BAGUS LAKSMANA ISWARA IF 273


CLASSIC MACHINE LEARNING



Pembagian Tugas

No	Nama Anggota	Tugas
1	AZIZ RAHMAD ARIFIN	Pembuatan Model
2	ISHAM HAWALI ARIJUDDIN	Merancang PPT
3	SULAIMAN FAIZ TSAQIB	Pembuatan Model
4	COKORDA BAGUS LAKSMANA ISWARA	Merancang PPT

LATAR BELAKANG





LATAR BELAKANG

Salama ini seluruh pelanggan diperlakukan sama, padahal profil dan perilaku belanjanya sangat beragam.

Pendekatan one-size-fits-all dalam pemasaran sering kali tidak efisien karena:

1. Biaya kampanye pemasaran tinggi namun tingkat konversi rendah.
2. Pelanggan bernilai tinggi tidak mendapat perhatian khusus.
3. Pelanggan sensitif harga tidak dijangkau dengan penawaran yang tepat.
4. Perusahaan kehilangan potensi revenue karena tidak mengenali segmen pasar.

LATAR BELAKANG

Customer segmentation menggunakan teknik machine learning (clustering) memungkinkan pengelompokan pelanggan secara otomatis berdasarkan data perilaku, sehingga perusahaan dapat menyesuaikan strategi untuk setiap segmen.

SUMBER DATASET

Dataset Customer Personality Analysis (Kaggle): 2.240 pelanggan retail, 29 kolom, periode pendaftaran 2012–2014.



VISHAKH PATEL · UPDATED 3 YEARS AGO

68

<> Code

Download

Customer Segmentation : Clustering

Customer Segmentation using KMeans Clustering Algorithm

Data Card

Code (62)

Discussion (0)

Suggestions (0)


About Dataset

Customer Personality Analysis involves a thorough examination of a company's optimal customer understanding of customers, enabling businesses to tailor products to meet the distinct need customer types.

By conducting a Customer Personality Analysis, businesses can refine their products based on segments. Rather than allocating resources to market a new product to the entire customer base, they can focus on the most likely to be interested in the product. Subsequently, targeted marketing efforts can be deployed, optimizing resource utilization and increasing the likelihood of successful product adoption.

Details of Features are as below:

This dataset has 29 features and 2240 records.

ID	Year_Birth	Education	Marital_Status	Income	Kids												
Unique identifier for each individual in the dataset.	The birth year of the individual.	The highest level of education attained by the individual.	The marital status of the individual.	The annual income of the individual.	The number of children in the household.												
		<table><tr><td>Graduation</td><td>50%</td></tr><tr><td>PhD</td><td>22%</td></tr><tr><td>Other (627)</td><td>28%</td></tr></table>	Graduation	50%	PhD	22%	Other (627)	28%	<table><tr><td>Married</td><td>39%</td></tr><tr><td>Together</td><td>26%</td></tr><tr><td>Other (796)</td><td>36%</td></tr></table>	Married	39%	Together	26%	Other (796)	36%		
Graduation	50%																
PhD	22%																
Other (627)	28%																
Married	39%																
Together	26%																
Other (796)	36%																
0	11.2k	1893	1996	1730	667k												
5524	1957	Graduation	Single	58138	0												
2174	1954	Graduation	Single	46344	1												
4141	1965	Graduation	Together	71613	0												
5324	1981	PhD	Married	58293	1												
7446	1967	Master	Together	62513	0												

<https://www.kaggle.com/datasets/vishakhapat/customer-segmentation-clustering/data>

DAFTAR FITUR

Id: Nomor identitas yang digunakan untuk membedakan setiap pelanggan.

Year_Birth: Tahun lahir pelanggan.

Education: Pendidikan terakhir yang dimiliki pelanggan.

Marital_Status: Status pernikahan pelanggan.

Income: Jumlah pendapatan pelanggan dalam satu tahun.

Kidhome: Jumlah anak kecil yang ada di rumah.

Teenhome: Jumlah anak remaja yang ada di rumah.

Dt_Customer: Tanggal pertama kali pelanggan terdaftar di perusahaan.

Recency: Jumlah hari yang sudah berlalu sejak pelanggan terakhir kali melakukan pembelian atau interaksi.

DAFTAR FITUR

- **MntWines:** Total pengeluaran pelanggan untuk membeli produk wine.
- **MntFruits:** Total pengeluaran pelanggan untuk membeli buah.
- **MntMeatProducts:** Total pengeluaran pelanggan untuk membeli produk daging.
- **MntFishProducts:** Total pengeluaran pelanggan untuk membeli produk ikan.
- **MntSweetProducts:** Total pengeluaran pelanggan untuk membeli makanan manis.
- **MntGoldProds:** Total pengeluaran pelanggan untuk membeli produk emas.
- **NumDealsPurchases:** Jumlah pembelian yang dilakukan pelanggan menggunakan promo atau diskon.
- **NumWebPurchases:** Jumlah pembelian yang dilakukan melalui website.
- **NumCatalogPurchases:** Jumlah pembelian yang dilakukan melalui katalog.
- **NumStorePurchases:** Jumlah pembelian yang dilakukan secara langsung di toko.
- **NumWebVisitsMonth:** Jumlah kunjungan pelanggan ke website setiap bulan.

DAFTAR FITUR

- **AcceptedCmp3:** Menunjukkan apakah pelanggan menerima kampanye pemasaran ke-3 (1 = ya, 0 = tidak).
- **AcceptedCmp4:** Menunjukkan apakah pelanggan menerima kampanye pemasaran ke-4 (1 = ya, 0 = tidak).
- **AcceptedCmp5:** Menunjukkan apakah pelanggan menerima kampanye pemasaran ke-5 (1 = ya, 0 = tidak).
- **AcceptedCmp1:** Menunjukkan apakah pelanggan menerima kampanye pemasaran ke-1 (1 = ya, 0 = tidak).
- **AcceptedCmp2:** Menunjukkan apakah pelanggan menerima kampanye pemasaran ke-2 (1 = ya, 0 = tidak).
- **Complain:** Menunjukkan apakah pelanggan pernah mengajukan keluhan (1 = ya, 0 = tidak).
- **Z_CostContact:** Nilai biaya yang digunakan sebagai biaya kontak pelanggan dan nilainya tetap.
- **Z_Revenue:** Nilai pendapatan yang digunakan dalam kampanye dan nilainya tetap.
- **Response:** Menunjukkan apakah pelanggan memberikan respons terhadap kampanye pemasaran (1 = ya, 0 = tidak).

Rumusan Masalah

1. Gimana cara mengelompokkan pelanggan berdasarkan profil dan kebiasaan belanja mereka?
2. Dari beberapa algoritma clustering, model mana yang paling cocok dan berapa jumlah cluster yang ideal?
3. Apa ciri khas masing-masing segmen, dan strategi marketing apa yang paling pas untuk tiap kelompok?

Solusi

Pakai teknik unsupervised learning (K-Means Clustering) untuk mengelompokkan pelanggan secara otomatis.

Langkah-langkahnya:

1. Bersihin data & bikin fitur baru yang lebih representatif
2. Standardisasi + reduksi dimensi pakai PCA
3. Bandingin 4 model di 42 kombinasi eksperimen
4. Profiling tiap cluster → persona + rekomendasi marketing

DATA & METODOLOGI

Data cleaning: hapus 24 baris income kosong, 2 kolom konstan, & 4 baris anomali (umur >110 th, income Rp666 juta).

Feature engineering: Age, Spent (total belanja), Purchases, Children, Family_Size, Total_Promos, dll.

Fitur yang skew di-log-transform, seluruh fitur di-standardize, lalu direduksi dengan PCA (4 komponen, ~86% variansi).

4 algoritma diuji — K-Means, Agglomerative, GMM, DBSCAN — pada data Scaled vs PCA, K = 2–8, dievaluasi dengan Silhouette, Calinski-Harabasz & Davies-Bouldin.



Dataset

Dataset: Customer Personality Analysis dari Kaggle

Berisi data profil dan perilaku belanja pelanggan sebuah perusahaan retail.

Atribut	Detail
Jumlah data awal	2.240 pelanggan
Jumlah data setelah cleaning	2.212 pelanggan
Jumlah fitur awal	29 kolom
Periode pendaftaran	Juli 2012 - Juni 2014
Data hilang	Income: 24 baris (~1%) - dihapus
Anomali dihapus	Year_Birth < 1901 (3 baris), Income = 666.666 (1 baris)
Kolom konstan dihapus	Z_CostContact, Z_Revenue

Fitur terbagi jadi 4 kategori:

- **Profil** — umur, pendidikan, status, income, jumlah anak
- **Belanja** — spending di 6 kategori produk (wine, daging, buah, dll)
- **Promosi** — respons terhadap 5 kampanye + pembelian pakai diskon
- **Channel** — pembelian via web, katalog, dan toko

Metode

A. Feature Engineering

Fitur Baru	Keterangan
Age	Umur pelanggan saat data diambil (2014)
Spent	Total belanja semua kategori produk
Purchases	Total transaksi (web + katalog + toko)
Children	Jumlah anak (Kidhome + Teenhome)
Family_Size	Jumlah anggota keluarga
Is_Parent	Punya anak atau tidak (binary)
Total_Promos	Jumlah kampanye yang diterima (1-5)
Customer_Days	Lama menjadi pelanggan (hari)

Dari 29 kolom asli, kita bikin 8 fitur baru yang lebih merangkum perilaku pelanggan — kayak total belanja (Spent), jumlah anak (Children), ukuran keluarga, dan lama jadi pelanggan.

Preprocessing

- Log transform untuk fitur yang distribusinya miring (Spent, NumDealsPurchases, dll)
- StandardScaler biar semua fitur di skala yang sama
- PCA (4 komponen, ~86% variansi) — mengurangi noise dan korelasi antar-fitur

Metode



4 algoritma diuji dengan pendekatan yang beda:

- K-Means — partisi berdasarkan jarak ke centroid
- Agglomerative — hierarchical, bottom-up
- GMM — probabilistik, berbasis distribusi Gaussian
- DBSCAN — berbasis kepadatan data

Evaluasi pakai 3 metrik:

- Silhouette Score — seberapa rapat & terpisah cluster (-1 s/d 1)
- Calinski-Harabasz — rasio sebaran antar vs dalam cluster
- Davies-Bouldin — kemiripan antar-cluster (makin kecil makin bagus)

Flowchart



Hasil Eksperimen


Skenario 1: Perbandingan Model & Data

Setiap kombinasi model × data diuji untuk K = 2 sampai 8. Total: 3 model × 2 jenis data × 7 nilai K = 42 eksperimen + DBSCAN terpisah.




Perbandingan Metrik Evaluasi Clustering


Silhouette



Calinski_Harabasz



Davies_Bouldin



Hasil Eksperimen





Kombinasi	K=2 Sil.	K=3 Sil.	K=4 Sil.	Catatan
KMeans (PCA)	0.393	0.351	0.293	Terbaik di semua K
KMeans (Scaled)	0.342	0.294	0.235	Konsisten, lebih rendah
Agglom. (PCA)	0.373	0.318	0.252	Kedua terbaik
Agglom. (Scaled)	0.321	0.270	0.202	Di bawah K-Means
GMM (PCA)	0.391	0.298	0.233	Baik di K=2, turun cepat
GMM (Scaled)	0.335	0.234	0.101	Tidak stabil $K \geq 4$

Temuan utama:

- Data PCA konsisten lebih baik dari Scaled di semua model
- K-Means unggul dibanding Agglomerative dan GMM di hampir semua K
- GMM nggak stabil di data Scaled untuk $K \geq 4$
- DBSCAN nggak cocok — data pelanggan tersebar kontinu, nggak membentuk cluster padat

Hasil Eksperimen

Skenario 2: Pemilihan Jumlah Cluster (K)



Kenapa K = 3?

- K=2 metriknya paling tinggi (Silhouette 0,393), tapi cuma memisahkan jadi 2 kelompok besar — terlalu kasar buat strategi
- K=3 turun sedikit (0,351) tapi memunculkan segmen menengah yang punya perilaku unik
- K=4 ke atas, metrik turun tajam dan elbow sudah melandai

MODEL TERPILIH: K-MEANS, $K = 3$

K-Means pada data PCA paling konsisten unggul dibanding Agglomerative & GMM di hampir semua nilai K.

K = 2 punya skor tertinggi (Silhouette 0,393), tapi terlalu kasar untuk strategi marketing (hanya 2 kelompok besar).

K = 3 dipilih: Silhouette 0,351, Davies-Bouldin 1,087 — turun sedikit namun menghasilkan segmen menengah yang bermakna.

Stabil diuji ulang pada 5 random seed berbeda (Adjusted Rand Index ≈ 1).

DBSCAN tidak cocok: data pelanggan tersebar kontinu, tidak membentuk cluster padat yang terpisah.

Hasil Eksperimen


Skenario 3: Uji Stabilitas

Model K-Means dilatih ulang pakai 5 random seed berbeda. ARI mendekati 1.0 di semua seed → model sangat stabil, nggak sensitif terhadap inisialisasi acak.


Random Seed	0	7	21	100	2024
ARI Score	1.000	0.999	0.997	1.000	1.000

Kesimpulan: ARI mendekati 1.0 di semua seed, artinya model sangat stabil dan tidak sensitif terhadap inisialisasi acak.


Model Terpilih	Metrik
K-Means Data: PCA (4 komponen) K = 3	Silhouette: 0.351 Calinski-Harabasz: 1621.07 Davies-Bouldin: 1.087



Hasil Eksperimen



Persona & Rekomendasi Marketing



Gambar 7: Distribusi umur, jumlah anak, status tinggal, dan pendidikan per cluster

3 SEGMENT PELANGGAN

PREMIUM

Cluster 0 — 645 pelanggan
(29%)

Income ~Rp75 jt/th

Total belanja ~Rp1.256rb
(60% dari total pendapatan)

Diskon: jarang dipakai (1,2x)

HEMAT

Cluster 1 — 878 pelanggan (40%)

Income ~Rp32 jt/th

Total belanja ~Rp71rb
(hanya 5% dari total pendapatan)

Kunjungan web tertinggi (6,6x/bln)

KELUARGA PEMBURU DISKON

Cluster 2 — 689 pelanggan (31%)

Income ~Rp55 jt/th

Total belanja ~Rp684rb
(35% dari total pendapatan)

Diskon tertinggi (4,0x), aktif di web & toko

PERSONA & REKOMENDASI

PREMIUM

- Income tinggi, jarang pakai diskon, sumbang 60% dari total pendapatan.
- Rekomendasi: program VIP/loyalitas, katalog eksklusif, produk premium (wine & daging). Diskon besar tidak diperlukan.

HEMAT

- Income rendah, mayoritas punya anak, sering buka web tapi jarang membeli, hampir tidak merespons kampanye.
- Rekomendasi: fokus konversi (voucher first purchase, pengingat keranjang), paket kebutuhan keluarga terjangkau.

KELUARGA PEMBURU DISKON

- Income menengah, hampir semua punya anak, sangat sensitif diskon, aktif di web & toko.
- Rekomendasi: promo bundling keluarga, flash sale online, promo wine — berpotensi naik ke level Premium.

KESIMPULAN & KETERBATASAN

K-Means pada data PCA dengan $K = 3$ memberi keseimbangan terbaik antara performa metrik (Silhouette 0,351) dan kemudahan interpretasi bisnis.

Pembeda utama antar-segmen: income, total belanja, keberadaan anak, dan sensitivitas terhadap diskon.

Keterbatasan: Silhouette 0,35 berarti batas antar-cluster tidak terlalu tegas — pelanggan tersebar kontinu, bukan mengumpul rapi.

Data berasal dari periode 2012–2014, sebaiknya diperbarui sebelum dipakai untuk keputusan bisnis saat ini.